

Kontingent-Limit — Ebene 2: Ausweichwege

Kontingent-Limit — Ebene 2: Ausweichwege

Status: bewusst NICHT gebaut. Diese Seite hält den Möglichkeitsraum fest, damit Adam entscheiden kann — sie ist keine Bauanleitung und löst nichts aus.

Ebene 1 ist gebaut (Punkt 5.31): Beim Kontingent-Limit geht nichts mehr verloren. Die Nachricht bleibt vorn in der Warteschlange, der Bot sagt in Klartext, bis wann pausiert wird, und holt danach alles der Reihe nach nach.

Conni-Empfehlung zur Reihenfolge: erst Ebene 1 laufen lassen und **messen, wie oft das Limit überhaupt beißt**. Ein Ausweichweg, der zweimal im Quartal gebraucht würde, lohnt den Aufwand und das Risiko nicht.

Grundsatz für jeden Ausweichweg

Ein Ausweichweg wird **angeboten, nie automatisch genommen**. Ein stiller Wechsel des Modells oder des Anbieters wäre genau die Art unsichtbarer Entscheidung, die weder zur Kostenregel noch zur Werte-Charta passt: Adam müsste hinterher raten, wer geantwortet hat und was es gekostet hat.

Die fünf Wege

Weg	Ampel	Was er bedeutet
A — API-Zweitweg		Derselbe Anbieter, anderer Geldtopf: ANTHROPIC_API_KEY statt Abo-Token. Technisch der

Weg	Ampel	Was er bedeutet
		kürzeste Weg, weil der Code beide Wege ohnehin kennt. Kostet pro Token — nur mit ausdrücklicher Freigabe und Ausgabengrenze.
B — lokales Modell		Ollama läuft bereits auf dem VPS. Datenschutzfreundlich und kostenfrei, aber der Server hat keine GPU ; für ein Modell, das den Hauptagenten ersetzen könnte, fehlt schlicht die Rechenleistung. Taugt für Neben-Inferenzen, nicht als Vertretung.
C — Zweit-Konto		Ein zweites Abo verdoppelt das Kontingent. Kostet eine weitere Grundgebühr und wirft die Frage auf, ob zwei Konten für eine Person im Sinne der Nutzungsbedingungen sind.
D — Fremdanbieter	–	Anderer Hersteller über LiteLLM. Neuer Datenabfluss, neue Vertragslage, andere Antwortqualität — und die Ampel-Regeln müssten für ihn neu durchdacht werden.
E — Zusatzguthaben		Adams eigene Ergänzung: Kontingent zukaufen statt ausweichen. Der ehrlichste Weg, weil nichts am Verhalten geändert wird — aber vor jedem Kauf eine Kostenschätzung.

Ehrliche Grenze bei der Vorwarnung

Eine Vorwarnung bei etwa 80 % Verbrauch wäre wünschenswert, ist über den Abo-Zugang aber **nicht sauber abfragbar**. Deshalb gilt: **nur Claudes eigene Warnmeldungen durchreichen, nichts approximieren**. Ein selbst geschätzter Füllstand wäre eine Zahl, die vertrauenswürdig aussieht und es nicht ist.

Was als Nächstes ansteht

1. Ebene 1 im Alltag beobachten — wie oft greift die Pause tatsächlich?
2. Erst mit dieser Zahl entscheiden, ob überhaupt ein Ausweichweg gebraucht wird.
3. Fällt die Wahl auf A oder E: -Dialog mit Kostenschätzung **vor** der Einrichtung, nicht danach.