

Modell- und Plattform-Strategie — Entscheidungs-Bericht

Erstellt: 23.07.2026, Recherche-Sitzung „Modell-Plattform-Strategie“ (Worktree, nur lesend im Repo) **Auftrag:** Vier Fragen (A–D) recherchieren und rechnen — keine Entscheidung, nichts installiert, keine Kosten verursacht (Recherche ausschließlich über kostenfreies WebFetch; die kostenpflichtige WebSearch wurde nicht benutzt). **Grundlagen gelesen:** CLAUDE.md (💰-Kostenregel), blaupause-notizen.md, MIGRATION.md (Phase 2, 9.6, 9.7), bestehender Hermes-Prüfbericht vom 23.07. **Entscheidung:** Adam, mit Kontroll- und Migrations-Sitzung beim Phasen-Audit.

Executive Summary

1. **Hermes (Frage A):** Das K.-o.-Kriterium bleibt bestehen — offiziell bindet Hermes Anthropic nur per bezahltem ANTHROPIC_API_KEY an. Es gibt zwar mehrere aktive Abo-Auth-Umbauten in der Community (Agent-SDK-Provider, claude -p-Backend), aber **keiner ist gemergt**, und Anthropic hat Abo-OAuth in Dritt-Tools seit April 2026 ausdrücklich verboten und technisch blockiert. Option A (Plattformwechsel) bleibt tot; Option B (Konzepte adaptieren) bestätigt.
 2. **Neuer, wichtiger Nebenbefund:** Die AGB-Verschärfung vom Frühjahr 2026 berührt auch **unseren eigenen** Betrieb (Agent SDK + Abo-Token). Die offizielle Doku liest sich für den Einzelnutzer-Eigenbetrieb weiterhin verträglich, verbietet aber Drittanbieter-Routing — Einordnung und Absicherungs-Vorschlag in Abschnitt D.
 3. **Alternativen (B):** „OpenAI-kompatibel“ ist ein Formatstandard, keine Firmen-Bindung. Fünf Kandidaten geprüft (OpenClaw, Hermes, Letta, Agent Zero, Khoj) — **keiner** trägt unsere verifizierten Invarianten (Persistenz, Wächter, Pre-Send, Ampel) und keiner löst die Abo-Auth-Frage besser als unser jetziger Bau. Empfehlung: Plattform behalten, Muster klauen.
 4. **Kosten (C):** Für unser Nutzungsprofil ist das **Max-Abo (~100 \$/Monat)** fast immer der **günstigste Claude-Weg** — die API-Rechnung läge je nach Auslastung bei grob 40–1.100 \$/Monat. Offene Modelle per Token (DeepSeek ≈ 7–90 \$/Monat) sind 10- bis 15-mal billiger, aber qualitativ und datenschutzseitig kein Hauptagent-Ersatz. Für Neben-Inferenzen und Spezialistenmodelle lohnt **nie** ein Abo.
 5. **Unabhängigkeit (D):** Realistisch heute: RAG/Memory + portable Struktur (haben wir) + dokumentierter Anbieter-Wechsel-Drill (fehlt als Übung). „Eigenes, sich weiterentwickelndes Modell“ = heute Feintuning offener Modelle (zweistellig–dreistellig € pro Lauf, begrenzter Nutzen) — echtes Training bleibt Zukunftsmusik (Millionenbereich). Kernprinzip für die Blaupause: **Daten und Regeln sind portabel, Modellgewichte nicht.**
-

A) Hermes Agent (Nous Research) — Tiefenprüfung

A.1 Faktenlage Anbindung (Voll-Doku jetzt gelesen)

Die Konfigurations-Doku (hermes-agent.nousresearch.com/docs/user-guide/configuration) nennt als Provider: Nous Portal (OAuth), OpenRouter, OpenAI/Codex, **Anthropic via ANTHROPIC_API_KEY**, MiniMax, xAI Grok (OAuth für deren Abonnenten) sowie **beliebige OpenAI-kompatible Endpoints via base_url** — darüber laufen auch Ollama und lokale Modelle. Damit ist die Lücke des ersten Prüfberichts geschlossen: Die Anthropic-Anbindung ist offiziell der **bezahlte API-Key-Weg**, ein Abo-Weg existiert im offiziellen Funktionsumfang nicht.

A.2 Inoffizielle Wege zum Abo-Zugang — ehrliche Bewertung

Die Issue-Lage zeigt, dass die Community genau daran arbeitet — es gibt **mindestens vier konkurrierende, allesamt ungemerzte** Ansätze:

Ansatz	Stand (23.07.2026)	Bewertung
PR #65982 — „claude-agent-sdk provider under subscription OAuth (fail-closed)“	offen; Maintainer-Review läuft, Grundsatzfrage (Core vs. Plugin) ungeklärt	Technisch sauberster Weg (offizielles SDK unter Hermes' eigener Schleife); nicht gemerzt = bei jedem Update Bruchgefahr
PR #67335 — „claude -p-CLI-Backend mit CLAUDE_CODE_OAUTH_TOKEN“	offen (19.07.); Maintainer: „selection needed“, konkurriert mit #40074/#56413	Nutzt die offizielle CLI („first party“) — derselbe Mechanismus wie unser Bot; als Fork-Pflege-Aufgabe dauerhaft
Credential-Pool mit sk-ant-oat-Tokens direkt gegen die API	teils gemerzt, aber Bug-Meldungen („out of extra usage“, HTTP 400)	Genau der Weg, den Anthropic seit 04.04.2026 serverseitig blockiert — instabil und AGB-widrig

AGB-Lage (Primärquelle, Claude-Code-Doku „Legal and compliance“): OAuth-Auth ist „intended exclusively ... to support ordinary use of Claude Code and other native Anthropic applications“. Entwickler, die Produkte/Dienste bauen — „including those using the Agent SDK“ — sollen API-Keys nutzen; Anthropic „does not permit third-party developers to ... route requests through Free, Pro, or Max plan credentials **on behalf of their users**“, Durchsetzung „without prior notice“. Sekundärquellen dokumentieren die technische Durchsetzung ab 04.04.2026 (Blockade von OpenClaw, OpenCode u. a.; Kontosperrungen teils binnen Minuten). ⚠ Einzelne Sekundärquellen zitieren einen schärferen Wortlaut („including the Agent SDK is not permitted“) — diesen Satz habe ich in der Primärquelle so nicht gefunden; maßgeblich ist der oben zitierte Text.

Konsequenz für Hermes: Selbst wenn einer der PRs gemerzt würde, wäre Hermes ein Dritt-Tool, das Abo-Zugang routet — die Konstellation, gegen die Anthropic aktiv vorgeht. Stabilität: abhängig von ungemerzten PRs und einem Katz-und-Maus-Spiel. **AGB-Risiko: hoch (Kontosperrung möglich).** Das K.-o.-Kriterium 1 aus 9.7 greift damit doppelt: technisch (kein offizieller Abo-Weg) und rechtlich (verboten).

A.3 Reifegrad, Community, Sicherheitslage (GitHub-API, hart gezählt)

- **Stars 219.225 · Forks 41.554 · offene Issues/PRs 24.870 · Watcher 835** — riesige, extrem aktive Community, aber die Issue-Zahl zeigt ein massives Triage-Problem.
- **Lizenz MIT, Sprache Python** — Fork-fähig und lesbar; gut für Konzept-Übernahme.
- **Repo angelegt 22.07.2025, letzter Push 23.07.2026, letztes Release v0.19.0 vom 20.07.2026.**
⚠ Korrektur zum ersten Prüfbericht: Das Repo ist laut GitHub-API ein Jahr alt, nicht erst seit Februar 2026 (vermutlich war Februar der öffentliche Start; ungeprüft). Versionsnummer 0.x + hohe Release-Frequenz = API-Brüche wahrscheinlich.

- **Sicherheitslage:** Command-Approval und Container-Isolation vorhanden (Erstbericht); die OAuth-/Credential-Pool-Bugs zeigen aber eine noch unreife Auth-Schicht. Datenwege über Nous Portal/OpenRouter wären gegen unsere Ampel-Architektur zu prüfen — entfällt mit dem K.-o.

A.4 Befund & Empfehlung A

Befund: Aussage bestätigt und verschärft — Anthropic ist in Hermes offiziell nur per bezahltem API-Key anbindbar; die Abo-Wege sind ungemergte Community-PRs mit hohem Stabilitäts- und AGB-Risiko. **Empfehlung: Option B beibehalten** (FTS5-Recall → 5.11, Playbook-Gedanke → 9.6, deterministische Memory-Kuratierung) und Hermes über den 5.21-Monitor beobachten — insbesondere, ob Anthropic je einen offiziellen Abo-Weg für Dritt-Frameworks öffnet (dann Neubewertung).

B) Alternativen-Landkarte: selbst-hostbare Agent-Frameworks

B.1 Vorab: Was „OpenAI-kompatibel“ wirklich heißt

„OpenAI-kompatibel“ bezeichnet den **Wire-Format-Standard** der POST /v1/chat/completions-Schnittstelle — de facto die lingua franca der Inferenz-Welt. Ollama, LiteLLM, vLLM, LM Studio und praktisch jeder Anbieter sprechen dieses Format. **Ein Framework, das „OpenAI-kompatible Endpoints“ verlangt, bindet uns nicht an die Firma OpenAI** — unser Grundsatz „kein OpenAI im Stack“ (2.5) bleibt vollständig wahrbar, indem der Endpoint auf Ollama/LiteLLM zeigt. Die eigentliche Sollbruchstelle ist eine andere: Der **Claude-Abo-Zugang** läuft *nicht* über dieses Standardformat, sondern nur über Claude Code / Agent SDK — deshalb ist „OpenAI-kompatibel als einziger Weg“ gleichbedeutend mit „Claude nur gegen API-Geld“ (K.-o.-Kriterium 9.7).

B.2 Kandidaten im Kurzprofil (Metriken: GitHub-API, 23.07.2026)

Kandi- dat	Stars	Lizenz	Telegram	Mem- ory	Skills/ Tools	MCP	Ollama/ lokal	Com- munity
Open- Claw (Type- Script, seit 11/2025)	383.873	„Other“ ⚠️ prüfen	✅ na- tiv (+ What- sApp/ Dis- cord/ Signal)	✅ Mark- down- Dateien	✅ Skills	✅	✅ (OI- lama, LM Stu- dio, vLLM u. a., 60+ Provider)	riesig
Hermes Agent (Python, MIT)	219.225	MIT	✅ nativ	✅ FTS5 + Kuratierung	✅ (agentskills.io)	✅	✅ via base_url	riesig, chaotisch
Letta (Python, seit 2023)	23.925	Apache-2.0	❌ (selbst bauen)	✅✅ Kernkom- petenz (MemGPT- Erbe, stateful)	✅	✅	✅	reif, fokussiert
Khoj (Python, seit 2021)	35.940	AGPL-3.0 ⚠️	❌ (What- sApp/ Web/ Ob- sidian/ Emacs)	✅ (RAG/ Second Brain)	teils (Au- toma- tionen)	ungeprüft	✅	reif
Agent Zero (Python)	18.493	„NOASSER- TION“ ⚠️ prüfen	❌ (Web- UI/ Desk- top)	✅ (Konso- lidierung, Snap- shots)	✅	✅	via Ope- nAI- kom- patibel (ungeprüft)	mittel

Einzeleinschätzungen:

- **OpenClaw** ist konzeptionell der nächste Verwandte unseres Bots (persönlicher Assistent, Messenger-Gateways, Datei-Memory). Bemerkenswert: Es führt einen Provider „**Anthropic (API + Claude CLI)**“ — der CLI-Modus fährt die offizielle `claude`-Binary, also denselben Mechanismus wie unser Agent SDK; der Gründer bezeichnete das nach dem April-Cut als den verbleibenden legitimen Weg. Gegenargumente: Sicherheitshistorie (Anfang 2026 massenhaft exponierte Instanzen dokumentiert), Lizenz laut GitHub-API nicht mehr als klare OSS-Lizenz ausgewiesen (prüfen!), TypeScript statt Python, und das Projekt stand im Zentrum des Anthropic-Enforcements.
- **Hermes** — siehe A; als Plattform K.-o., als Ideen-Steinbruch erstklassig.

- **Letta** ist der seriöseste Kandidat nach klassischen Kriterien (Apache-2.0, drei Jahre Reife, nur 49 offene Issues): eine **Memory-/Agent-Server-Schicht**, kein fertiger Telegram-Assistent. Für unsere Blaupause interessant als Referenzarchitektur für „stateful Memory als eigener Dienst“ — ein Umstieg würde aber bedeuten, Telegram-Gateway, Ampel, Wächter usw. selbst dort hineinzubauen: gleicher Eigenbau, fremdes Fundament.
- **Khoj** ist ein „Second Brain“ (Wissens-RAG) mit Assistent obendrauf — stark für Punkt „Buch des eigenen Schaffens“, schwach als Steuerzentrale; kein Telegram; **AGPL** wäre bei späterer Kundenfähigkeit sorgfältig zu prüfen (Copyleft auch bei Netzwerknutzung).
- **Agent Zero** punktet mit Docker-Isolation und einem interessanten Memory-Design (Konsolidierung, „Time Travel“), hat aber kein Telegram-Gateway, eine unklare Lizenz-Auszeichnung und — bezeichnend — Claude-Code-Anbindung erst „in Planung“, während Codex-OAuth schon da ist.
- **Bewusst Big-Tech-unabhängig ausgelegt** sind vor allem Khoj und Agent Zero (self-host-first, lokale Modelle als gleichwertige Bürger); OpenClaw und Hermes sind Provider-agnostisch, leben praktisch aber von den großen Anbietern.

B.3 Befund & Empfehlung B

Kein Kandidat besteht das K.-o.-Kriterium besser als unser Eigenbau: Der Claude-Hauptagent über das Abo läuft nur im Claude-Code-/Agent-SDK-Ökosystem — genau dort sitzt unser Bot bereits. Alle Kandidaten würden bedeuten: verifizierte Invarianten (5.2-Persistenz, 5.18-Wächter, 8.5-Pre-Send, Ampel, Kostenregel) in fremden, schnell drehenden Code portieren. **Empfehlung:** Plattform behalten; für die Blaupause (9.6) je Kandidat das beste Muster notieren — OpenClaw: Messenger-Gateway-Abstraktion + Claude-CLI-Provider-Gedanke; Hermes: FTS5-Recall + Skill-Playbooks; Letta: Memory als eigenständige, versionierte Dienstschicht; Agent Zero: Container-Isolation des Werkzeug-Raums; Khoj: Wissens-RAG fürs „lebende Buch“.

C) Abo vs. Token — Modellrechnung für unser Profil

C.1 Annahmen (offengelegt — bitte beim Audit gegenprüfen)

- **50–150 Anfragen/Tag**, 30 Tage/Monat → 1.500–4.500 Anfragen/Monat.
- Eine „Anfrage“ an einen **Agenten** ist kein einzelner API-Call: Tool-Schleifen, Systemprompt und Verlauf werden je Turn mitgesendet. Ansatz pro Anfrage: **10.000–40.000 Input-Token** (inkl. Kontext/Tools, gemischt leicht/schwer) und **500–2.000 Output-Token**. Das ergibt **15–180 Mio. Input- und 0,75–9 Mio. Output-Token pro Monat**.
- Preise Claude (offizielle Referenz, Stand heute): Opus 4.8 **5/25 \$**, Sonnet 5 **3/15 \$** (Intro 2/10 \$ bis 31.08.2026), Haiku 4.5 **1/5 \$** je Mio. Input/Output; Prompt-Cache-Reads $\approx 0,1 \times$ Input; Batch –50 %. Max-Abo: **ab 100 \$/Monat** (Adams Bestand: ~ 100 €).
- DeepSeek (offizielle Preisseite): V4-Pro **0,435/0,87 \$**, V4-Flash **0,14/0,28 \$** (Input Cache-Miss/Output je Mio.). Qwen/Llama über OpenRouter: Extraktion war unzuverlässig — Größenordnung „zwischen DeepSeek und Sonnet“, **ungeprüft**.

C.2 Monatskosten im Vergleich (gerundet, ohne/mit Cache)

Weg	Untere Bande (50/Tag, leicht)	Obere Bande (150/Tag, schwer)
Claude Max-Abo	~100 \$ fix	~100 \$ fix (bis zur Abo-Grenze; 20x-Stufe ~200 \$)
Claude API Opus 4.8	~94 \$ (mit ~80 % Cache-Reads: ~40 \$)	~1.125 \$ (mit Cache: ~480 \$)
Claude API Sonnet 5	~56 \$ (Cache: ~24 \$)	~675 \$ (Cache: ~290 \$)
Claude API Haiku 4.5	~19 \$	~225 \$
DeepSeek V4-Pro	~7 \$	~86 \$
DeepSeek V4-Flash	~2 \$	~28 \$
Lokal (heutiger VPS, CPU)	0 € — aber nur Kleinstmodelle (Phi-4-Mini-Klasse)	ungeeignet für Hauptagent
Lokal (eigene Hardware)	einmalig: gebrauchte 24-GB-GPU ~600–800 € oder Mac mit 64–128 GB RAM ~2.200–4.500 €; laufend Strom grob 10–30 €/Monat (Schätzwerte, marktabhängig, ungeprüft)	trägt 30B–120B-Klasse quantisiert — gut, aber nicht Claude-Niveau

C.3 Wann kippt die Rechnung?

1. **Abo vs. Claude-API:** Schon die untere Bande liegt in Opus-Qualität nahe am Abo-Preis, die obere weit darüber. **Für einen täglichen Agenten in Claude-Qualität ist das Abo praktisch immer der günstigste und planbarste Weg.** Die API gewinnt nur bei sehr geringer Nutzung (grob unter 20–30 leichten Anfragen/Tag ohne Tool-Schleifen — dann wären mit Haiku/Sonnet + Caching auch 10–40 \$/Monat drin) oder wenn AGB/Skalierung sie erzwingen (Kundenbetrieb!).
2. **Claude vs. offene Modelle per Token:** Kostenseitig gewinnt DeepSeek/Qwen um Faktor 10–50. Die Rechnung kippt aber nicht über den Preis, sondern über **Qualität** (Agent-Zuverlässigkeit, Werkzeugführung, Deutsch) und **Datenschutz** (DeepSeek = chinesischer Anbieter; nach unserer Ampel allenfalls für grüne Neben-Inferenzen denkbar, und selbst das wäre ein bewusster Entscheid gegen die bisherige „lokal statt Cloud“-Linie von 2.4). 💰-Hinweis: Jede dieser Routen wäre eine neue Kostenquelle und braucht vor Einrichtung Adams Freigabe.
3. **Lokal:** Kippt erst mit eigener Hardware-Investition, und auch dann nur für Aufgaben unterhalb des Hauptagenten. Sinnvollster Zeitpunkt: wenn ein konkreter Bedarf (Rot-Inferenzen in besserer Qualität, TTS/STT, lange Zusammenfassungen) die Anschaffung rechtfertigt — nicht als Selbstzweck.
4. **„Mehrere spezialisierte Modelle parallel“:** Für Neben-Rollen (Ampel-Klassifizierung, Labels, Kurz-Zusammenfassungen, Embeddings, Vision-Kleinkram) lohnt **niemals** ein eigenes Abo: Das Volumen je Rolle ist winzig, Abos bepreisen aber Dauerlast. Faustregel für die Blaupause: **Abo nur für das eine Arbeitspferd mit hohem Dauervolumen; alles Spezialisierte lokal (0**

€), **Free-Tier oder pay-per-token in Cent-Höhe** — Letzteres stets mit 💰-Freigabe. Genau so ist unser Stack heute schon gebaut (F1-Entscheid + Ollama).

D) Unabhängigkeits-Roadmap

D.1 Risiken der Ein-Anbieter-Abhängigkeit — konkret belegt

Risiko	Beleg/Einordnung
AGB-Änderung + Kontosperrung	Real vorgeführt: Doku-Verschärfung Feb. 2026, technische Blockade von Dritt-Tools zum 04.04.2026, dokumentierte Sper- rungen. Betrifft uns indirekt: Unser Bot fährt Agent SDK + Abo-Token — die Primärquelle deckt „ordinary, individual usage of Claude Code and the Agent SDK“ über die Limit-For- mulierung, verbietet aber Drittanbieter-Routing „on behalf of their users“. Einzelnutzer-Eigen- betrieb über die offizielle CLI ist die verträglich- ste Lesart — Restrisiko aber nicht null , Durchsetzung „without prior notice“.
Preiserhöhung	Max heißt inzwischen „ ab 100 \$“; API-Preise haben sich 2025/26 mehrfach bewegt. Kalku- lation nie auf einen Preisstand festnageln.
Modell-Abkündigung	Anthropic führt belegte Retirement-Zyklen (~12–18 Monate je Modellgeneration). Unser 5.21-Monitor + „Modellwahl ist Konfiguration“ fangen das ab.
Werkzeug-Kopplung	Agent-Fähigkeiten (Tools, Permissions, Ses- sions) sind ans Claude-Code-Ökosystem gebunden — der eigentliche Lock-in liegt weniger im Modell als im Agent-Harness .

D.2 Absicherungs-Stufen auf Basis des Bestands

Stufe 0 — haben wir bereits: lokales Ollama-Fallback (2.3), LiteLLM als Provider-Abstraktion der Neben-Inferenzen (2.6), SearxNG statt Anbieter-Suche (2.7), Git-Redundanz + Offline-Bundles (4.x), „Struktur über Namen“, Modellwahl als Konfiguration, Blaupause-Sammlung. Das ist mehr, als die meisten Projekte je aufbauen.

Stufe 1 — jetzt, kostenlos, gehört in die Blaupause: - **Notbetriebs-Drill:** einmal bewusst durchspielen (Testlauf), dass der Bot bei ausgefallenem Claude-Zugang auf „degradierten Modus“ (lokales Modell, ehrliche Kennzeichnung) umschaltet — der Mechanismus existiert, die geprobte Prozedur nicht. - **Rollenprofil „Hauptagent“ modellneutral beschreiben:** Welche Fähigkeiten braucht die Rolle (Werkzeugaufrufe, Freigabe-Schleife, Streaming, Kontextgröße, Deutsch)? Damit wird jeder künftige Kandidat in Stunden statt Tagen prüfbar. - **API-Key-Notweg dokumentieren,**

nicht aktivieren: Falls der Abo-Weg je bricht, ist der geordnete Rückfall „Sonnet 5 + Caching + Spend-Limit per API-Key“ — als beschriebene Prozedur mit 💰-Warnung, ohne dass ein Key im Stack liegt. - **AGB-Wachposten:** Die Claude-Code-Legal-Seite in den 5.21-Monitor aufnehmen (Änderungen an der Auth-Passage = sofortige Meldung). Die ⚠️-Notiz in CLAUDE.md („AGB-Grenze ungeprüft, Quelle 14 Monate alt“) kann die führende Sitzung mit dieser Recherche auf Stand 07/2026 heben.

Stufe 2 — mittelfristig, je ein bewusster Entscheid: Zweit-Cloud-Route für grüne Neben-Inferenzen über LiteLLM (Groq-Free bereits geprüft; DeepSeek/Qwen nur nach Datenschutz-Abwägung); stärkeres lokales Modell, sobald reale Aufgaben es verlangen.

Stufe 3 — langfristig: eigene Inferenz-Hardware (siehe C.2), wenn Rot-Aufgaben oder Kosten es tragen.

D.3 „Eigenes, sich weiterentwickelndes Modell“ — nüchtern

- **Training from scratch:** Zukunftsmusik. Selbst kleine brauchbare Modelle kosten im Training Rechenleistung im sechs- bis siebenstelligen Euro-Bereich plus Datenpipeline und Team — für uns auf Jahre irrelevant.
 - **Feintuning offener Modelle (LoRA/QLoRA auf 7–14B):** heute machbar; ein Lauf auf gemieteten GPUs liegt grob im zweistelligen bis niedrigen dreistelligen Euro-Bereich (**Schätzwert, ungeprüft**). Realer Nutzen: Ton, Formate, feste Abläufe. Nicht erreichbar: mehr Intelligenz, aktuelles Wissen. Pflegelast: jedes Basismodell-Update erfordert neues Tuning.
 - **Der ehrliche Befund:** Was Adam als „sich weiterentwickelndes Modell“ anstrebt, bauen wir bereits — nur an der richtigen Stelle: **Die Weiterentwicklung liegt in Memory, Regeln, Playbooks und Logs (RAG statt Gewichte)**. Diese Ebene ist modellportabel, versionierbar (Git) und überlebt jeden Anbieterwechsel; ins Modell eintrainiertes Verhalten ist all das nicht. Feintuning wird erst dann interessant, wenn eine klar umrissene, repetitive Rolle (z. B. der Coach-Klon mit festem Stil) auf einem lokalen Modell laufen soll.
-

Entscheidungsoptionen fürs Phasen-Audit

Option	Inhalt	Einschätzung
Beibehalten	Hauptagent auf Agent SDK + Abo; Hermes-Option B; Neben-Inferenzen lokal	Empfohlen — kein Kandidat und keine Kostenrechnung spricht für einen Wechsel
Erweitern (empfohlene Ergänzungen)	(1) AGB-Wachposten + aktualisierte AGB-Notiz in CLAUDE.md; (2) Notbetriebs-Drill einmal proben; (3) Rollenprofil „Hauptagent“ + API-Key-Notweg in die Blaupause; (4) Muster-Übernahmen aus B.3 als Blaupause-Zeilen	geringer Aufwand, deutlicher Zugewinn an Unabhängigkeit
Umbauen	Plattformwechsel (Hermes/OpenClaw/Letta) oder Modellwechsel des Hauptagenten	Nicht empfohlen — K.-o.-Kriterium, Portierungsrisiko der verifizierten Bausteine, kein Kostenvorteil

Was JETZT in die Blaupause gehört, um alle Türen offen zu halten: das Abo-Auth-K.-o.-Prüfprinzip (steht schon drin) · „Abo nur fürs Arbeitspferd, Spezialisten nie per Abo“ (C.3) · modellneutrales Rollenprofil des Hauptagenten · gestufter Notbetrieb mit geprobtem Drill · „Daten und Regeln sind portabel, Gewichte nicht“ · OpenAI-kompatibel = Formatstandard, nicht Firmenbindung.

Quellen

1. Hermes Agent — Repo & Doku: github.com/NousResearch/Hermes-Agent · hermes-agent.nousresearch.com/docs (+ [/docs/user-guide/configuration](https://docs.user-guide/configuration)) · GitHub-API-Metriken 23.07.2026
2. Hermes Abo-Auth-PRs: github.com/NousResearch/Hermes-Agent — PR #65982, PR #67335 (dazu referenziert: #40074, #56413, Issues #65564, #65365, #63737/63738)
3. Anthropic (Primärquelle AGB): code.claude.com/docs/en/legal-and-compliance — Abschnitt „Authentication and credential use“
4. Enforcement/Einordnung (Sekundärquellen, teils widersprüchlich im Wortlaut): openclaw.report/ecosystem/anthropic-bans-oauth-tokens-third-party-tools · kersai.com/anthropic-killed-third-party-claude-access-heres-every-workaround-that-still-works · dev.to/thenewstack (Überschriften; Volltexte teils nicht abrufbar)
5. Alternativen (GitHub-API 23.07.2026 + Doku): github.com/openclaw/openclaw + docs.openclaw.ai/providers · github.com/letta-ai/letta · github.com/frdel/agent-zero (+ README) · github.com/khoj-ai/khoj + docs.khoj.dev
6. Preise: Claude-Modellpreise aus der offiziellen API-Referenz (Skill-Dokumentation Anthropic, Cache-Stand 06/2026) · claude.com/pricing (Abo-Pläne) · api-docs.deepseek.com/quick_start/pricing (V4-Flash/V4-Pro)

7. Als **ungeprüft** gekennzeichnet: OpenRouter-Preise für Qwen/Llama (Extraktion unzuverlässig), Hardware-/Strom-/Feintuning-Kosten (Marktschätzungen), Hermes-Start „Februar 2026“.